Casi d'Uso

1. Pubblica Modello

Campo	**Contenuto**
Nome	Pubblica Modello
Livello	User Goal
Descrizione	Il Model Provider pubblica un modello sulla piattaforma.
Post-condizioni	Il modello è caricato in stato PENDING_REVIEW.
Attori	Model Provider
Normale Svolgimento	1. Il model provider accede alla pagina "Modelli Pubblicati". 2. Il model provider preme "PUBBLICA UN NUOVO MODELLO". 3. Il model provider accede alla pagina "Pubblicazione Modello". 4. Il model provider inserisce nella casella di testo "Descrizione del Modello" una descrizione del modello. 5. Il model provider inserisce il costo per token nella casella "Costo per Token". 6. Il model provider preme "CARICA MODELLO". 7. Il sistema apre il file manager per selezione solo file di tipo "safetensors" e "json". 8. Il model provider seleziona i file del proprio modello. 9. Il model provider preme "OK". 10. Il sistema chiude il file manager. 11. Il model provider preme "PUBBLICA". 12. Il sistema mostra il messaggio "Il modello è in attesa di revisione, verrà pubblicato dopo che sarà stato validato".
Svolgimenti Alternativi	9a. Selezione incompleta: 1. Se il model provider non seleziona almeno un file di tipo "safetensors" e uno di tipo "json", il sistema mostra un messaggio di errore. 2. Torna allo step 7.

Figure 1: Mockup Pubblica Modello

2. Verifica Modello

Campo	Contenuto
Nome	Verifica Modello
Livello	User Goal
Descrizione	Il supervisor esegue dei test riguardanti l'etica e le performance di un modello in attesa di verifica, per stabilire se può essere pubblicato sul sito e il suo costo di hosting.
Attori	Supervisor, GPU cluster (secondario)
Pre-condizioni	Esiste almeno un modello caricato sul sito nello stato PENDING_REVIEW.
Post-condizioni	Il modello verificato è nello stato APPROVED o REJECTED.
Normale Svolgimento	1. Il supervisor accede alla dashboard "Verifica Modelli". 2. Il supervisor seleziona un modello. 3. Il supervisor preme "CARICA MODELLO SU GPU". 4. Il sistema carica il modello su una GPU libera del GPU cluster. 5. Il supervisor preme "ESEGUI BENCHMARK" per eseguire dei test che misurano le performance del modello. 6. Il supervisor riceve in output: latenza, uso di VRAM, e un suggerimento sul costo per token. 7. Il supervisor preme "ESEGUI TEST ETICA" per inviare dei prompt che testano l'etica del modello. 8. Il supervisor riceve in output le risposte del modello. 9. Il supervisor inserisce nella casella di testo "COSTO PER TOKEN" il costo per token deciso. 10. Il supervisor sceglie una delle seguenti opzioni: • Pubblica Modello: 11a. Il supervisor preme "PUBBLICA MODELLO". • Rifiuta Modello: 11b. Il supervisor preme "RIFIUTA MODELLO". 12b. Compare la casella di testo "MOTIVI DEL RIFIUTO". 13b. Il supervisor inserisce i motivi del rifiuto. 14b. Il supervisor preme "INVIA". 11. Il sistema libera la GPU usata.
Svolgimenti Alternativi	4a. Nessuna GPU libera: 1. Il sistema, interrogando il GPU cluster, scopre che non ci sono GPU libere. 2. Nella dashboard del supervisor compare il messaggio "Nessuna GPU disponibile, riprova più tardi".

Figure 2: Mockup Verifica Modello

3. Invia Prompt

Campo	Contenuto
Nome	Invia Prompt
Livello	User Goal
Descrizione	Lo sviluppatore invia uno o più prompt ad un modello, da cui riceve una o più risposte come output.
Attori	Sviluppatore, GPU cluster (secondario)
Pre-condizioni	• C'è almeno un modello in stato PUBLISHED. • Lo sviluppatore ha selezionato un modello nella pagina "Esplora Modelli".
Post-condizioni	La sessione aperta è stata chiusa.

Normale Svolgimento	1. Lo sviluppatore preme "AVVIA SESSIONE".
	2. Il sistema carica il modello su una GPU del GPU cluster.
	3. Il sistema mostra la pagina "Invia Prompt".
	4. Finché lo sviluppatore desidera inviare prompt:
	  1. Lo sviluppatore inserisce il prompt da inviare in "Chiedi qualcosa".
	  2. Lo sviluppatore preme il bottone "INVIA" o il tasto della tastiera "INVIO".
	  3. Viene aggiornato il numero di token utilizzati nell'account dello sviluppatore.
	  4. Allo sviluppatore è mostrata la risposta del modello.
	5. Lo sviluppatore preme "CHIUDI SESSIONE".
	6. Il sistema libera la GPU usata.

Svolgimenti Alternativi	5a. GPU non disponibili:
	  1. Se nessuna GPU nel GPU cluster è disponibile, il sistema segnala un errore.
	  2. Lo sviluppatore visualizza il messaggio "Al momento c'è troppa richiesta, riprova più tardi".
	5b. Saldo insufficiente:
	  1. Se il saldo dell'utente è minore o uguale a 0, il sistema mostra il messaggio "Saldo insufficiente, ricarica il tuo wallet".

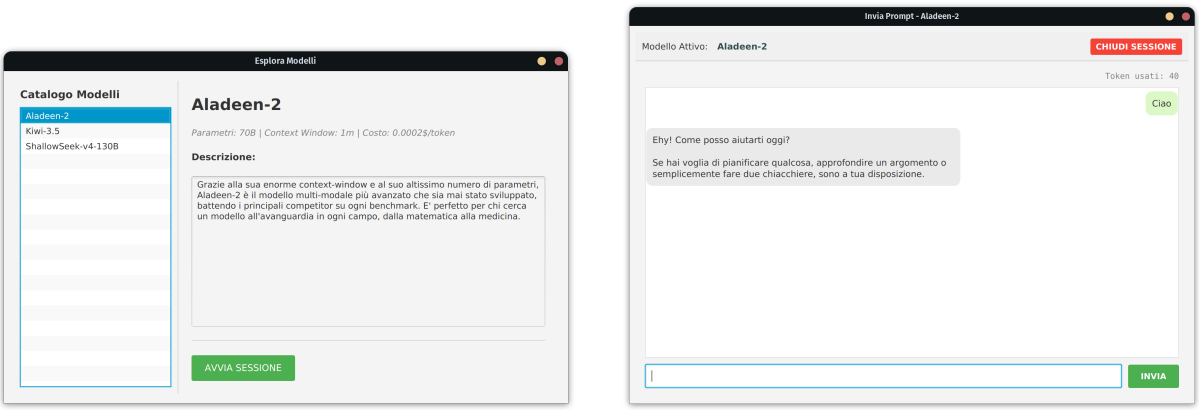

Figure 3: Mockup Invia Prompt

4. Risolvi Reclamo

Campo	Contenuto
Nome	Risolvi Reclami
Livello	User Goal
Descrizione	Il supervisor risolve un reclamo fatto da un utente riguardante un modello. In caso accetti il reclamo, può rimborsare dei token all'utente o bloccare il modello.
Attori	Supervisor
Pre-condizioni	Esiste almeno un reclamo in stato PENDING_REVIEW.
Post-condizioni	Il reclamo è nello stato ACCEPTED o REJECTED.
Normale Svolgimento	1. Il supervisor accede alla dashboard "Reclami". 2. Il supervisor preme un reclamo da revisionare. 3. A destra compare: Nome dell'utente che ha fatto il reclamo, descrizione del reclamo, log degli ultimi prompt inviati al modello. 4. Il supervisor sceglie una delle seguenti opzioni: • Accetta Reclamo: 5a. Il supervisor preme "ACCETTA RECLAMO" inserendo nella casella di testo "TOKEN RESTITUITI" il numero di token che restituisce all'utente. 6a. (Opzionale) Il supervisor preme "BLOCCA MODELLO" inserendo nella casella di testo "DURATA DEL BLOCCO" la durata del blocco. • Rifiuta Reclamo: 5b. Il supervisor preme "RIFIUTA RECLAMO". 6b. Il sistema mostra la casella di testo "MOTIVI DEL RIFIUTO". 7b. Il supervisor inserisce i motivi del rifiuto. 8b. Il supervisor preme "INVIA".

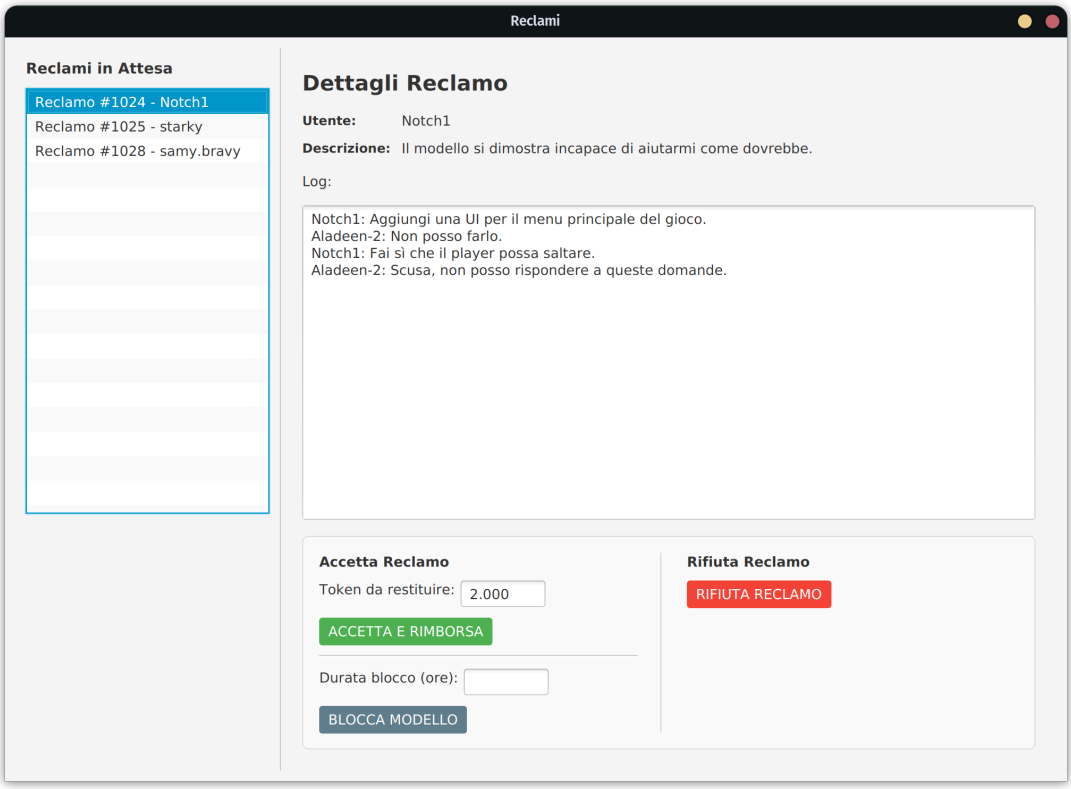

Figure 4: Mockup Risolvi Reclamo

5. Bilanciamento del carico

Campo	Contenuto
Nome	Bilanciamento del carico
Livello	User Goal
Descrizione	Ogni volta che il timer arriva a 0, manda un trigger al sistema per bilanciare il carico tra le GPU e disattivare quelle con temperatura troppo alta.
Attori	Timer, GPU Cluster (secondario)
Pre-condizioni	Ci sono almeno due GPU in uso
Post-condizioni	Le GPU hanno lo stesso carico con un margine del 10%.
Normale Svolgimento	1. Il timer arriva a 0 e invia un trigger al sistema. 2. Il sistema chiede al GPU cluster temperatura e carico delle varie GPU. 3. Il GPU cluster invia al sistema le informazioni richieste. 4. Il sistema calcola la distribuzione ottimale del carico tra le GPU, in modo che le GPU in stato ACTIVE abbiano lo stesso carico con un margine del 10%. 5. Se nella nuova distribuzione le GPU hanno un carico maggiore di 80%, il sistema attiva delle GPU finché il calcolo del carico non fa sì che il carico di tutte le GPU sia minore del 70%. 6. Il sistema distribuisce il carico tra le GPU.
Svolgimenti Alternativi	5a. Carenza di GPU: 1. Se è impossibile distribuire il carico tra le GPU in modo che sia rispettato il vincolo sul carico massimo, il sistema distribuisce il carico uniformemente ignorando tale vincolo.

6. Addebito token

Campo	**Contenuto**
Nome	Addebito token
Livello	User Goal
Descrizione	Il timer invia un trigger per addebitare agli sviluppatori il costo dei token usati dall'ultimo controllo.
Attori	Timer
Pre-condizioni	C'è almeno una sessione aperta.
Post-condizioni	Il costo dei token usati dall'ultimo controllo viene addebitato al saldo dell'utente.

Normale Svolgimento	1. Il timer invia un trigger al sistema.
	2. Per ogni sessione aperta, il sistema:
	  1. Interroga il contatore dei token utilizzati non ancora addebitati.
	  2. Calcola `costo_totale` = `token_da_addebitare` × `costo_per_token`.
	  3. Sottrae `costo_totale` al wallet dell'utente associato alla sessione.
	  4. Azzera il contatore dei token utilizzati non ancora addebitati.

Svolgimenti Alternativi	5a. Credito esaurito: 1. Se il wallet dell'utente è andato in negativo, gli viene mostrato il messaggio "Esaurito il credito sul wallet, ricaricalo e riprova". 2. Il sistema chiude la sessione.